Ejercicio 01 · Dataset público y SVM reproducible

INF-8239 Ciencia de Datos II (UASD) · Unidad 01 · Integración de LAB01 y LAB02

Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad01-01
Fecha de ejecución	2026-11-05
Aprobación del docente	**Pendiente.** El manual de la Unidad 01 prohíbe continuar con el entrenamiento final sin la aprobación del docente sobre el dataset: el entrenamiento de este repositorio se ejecutó con esa aprobación todavía pendiente y así queda declarado en `reports/dataset_svm_metrics.json` (`aprobacion_docente: pendiente`).

1. Identificación del dataset (LAB02)

Adult (Census Income) · UCI Machine Learning Repository · licencia **CC BY 4.0**.
URL `https://archive.ics.uci.edu/static/public/2/adult.zip`
Ficha `https://archive.ics.uci.edu/dataset/2/adult`
48.842 filas x 15 columnas; partición estratificada 80/20 con semilla 42 (39.073 entrenamiento / 9.769 prueba).
Target **income** (<=50K / >50K, 23,93 % positivos).
Variables usadas: age, workclass, education, education_num, marital_status, occupation, relationship, capital_gain, capital_loss, hours_per_week.
Columnas excluidas por motivo semántico y de equidad: fnlwgt, race, sex, native_country.
El candidato alterno evaluado fue *Bank Marketing* (UCI, CC BY 4.0), que exige excluir *duration* por fuga de información. La ficha comparativa completa está en `docs/ficha_dataset.md`.
LAB01 usa el dataset de diagnóstico de mama de Wisconsin incluido en scikit-learn (569 muestras, 30 variables, 2 clases).

SHA-256 del ZIP: `7537312dd56c2b98035880805ce99e68183a30ee468aa5329d6df0fbb3cc21bb`
SHA-256 del CSV normalizado: `9479f8b76861e48c66836d97937f2c5a469581672e12c795d770b297817ae3a1`
(ambos verificables desde la raíz del proyecto con `sha256sum -c data/raw/*.sha256`).

2. Tabla principal de resultados

Laboratorio	Modelo	Accuracy	F1 macro	Recall	ROC-AUC
LAB01 · Wisconsin	DummyClassifier (baseline)	0,6316	0,3871	0,0000	0,5000
LAB01 · Wisconsin	SVC rbf, C=10 gamma=0.01	0,9825	0,9812	0,9762	0,9977
LAB02 · Adult	DummyClassifier (mismo preprocesamiento)	0,7607	0,4320	0,0000	0,5000
LAB02 · Adult	SVC rbf con pipeline, C=10 gamma=0.1	0,8588	0,7928	0,6146	0,8840

Recall de la clase costosa: en LAB01 la clase maligno (0 = maligno); en LAB02 la clase **>50K**. **ROC-AUC** (área bajo la curva ROC de la clase positiva, la que pide el manual en LAB01 §8): en LAB01 la clase positiva es benigno (target = 1) y la clase costosa, maligno, da prácticamente el mismo valor (0,9977 frente a 0,9977); en LAB02 la clase positiva es >50K y alcanza 0,8840. F1 macro de validación: 0,9739 (LAB01, 5 folds) y 0,7759 (LAB02, submuestra estratificada del 25 %; el mejor modelo se reajustó sobre las 39.073 filas de entrenamiento). LAB02 deja fuera 901 de 2.338 casos que superan el umbral de ingreso.

2.1 Perfil real de los falsos negativos (LAB02)

El desglose se calcula desde los datos y se publica en `reports/dataset_svm_errors_profile.csv` y `.json`.

Ámbito	Falsos negativos	Nivel educativo	capital_gain = 0
Muestra de 20 errores (semilla 42)	12	HS-grad 6 · Bachelors 3 · Some-college 3	11 de 12
Prueba completa	901	HS-grad 357 · Some-college 211 · Bachelors 117 · Assoc-voc 57 · Masters 50 · otras 109	853 de 901

El falso negativo **no** se concentra en las personas con estudios superiores: en la muestra solo 3 de 12 tienen estudios superiores (6 tienen estudios secundarios y 3 tienen estudios no terminados), y 11 de 12 no tienen ganancia de capital (el único con ganancia de capital, 3103 USD, tiene nivel educativo HS-grad). El perfil es el de quien declara ingresos altos sin señales de capital.

3. Figuras

Figura 1. LAB01 · matriz de confusión del SVM sobre el conjunto de prueba.

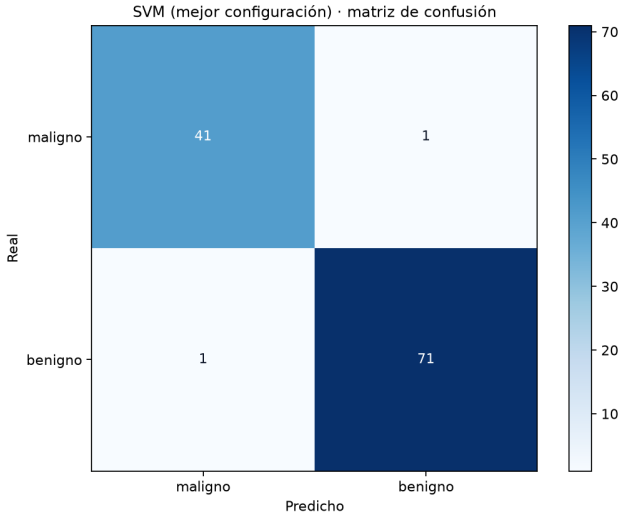
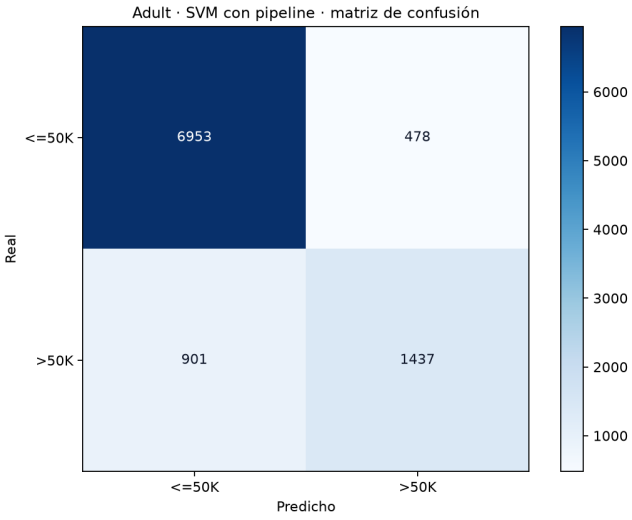


Figura 2. LAB02 · matriz de confusión del SVM con pipeline sobre el conjunto de prueba.



4. Conclusión

Qué se construyó. Dos experimentos reproducibles con el mismo esqueleto de proyecto: un pipeline de SVM con estandarización dentro del `Pipeline` sobre el dataset de diagnóstico de mama de Wisconsin (LAB01), y un pipeline completo con `ColumnTransformer` (imputación + escala para variables numéricas, imputación + codificación one-hot para categóricas) sobre el dataset público **Adult (Census Income)** de UCI (LAB02), elegido tras comparar dos candidatos verificados y documentado en `docs/ficha_dataset.md`.

Resultados. En LAB01 el baseline `DummyClassifier` alcanza 0,6316 de exactitud y 0,3871 de F1 macro (recall 0 para la clase maligno, porque predice siempre la mayoritaria) y el SVM con `C=10, gamma=0.01` llega a **0,9825 de exactitud y 0,9812 de F1 macro** en la prueba, con un único falso negativo sobre 42 casos malignos (recall 0,9762) y un **ROC-AUC de 0,9977** para la clase positiva y otro de 0,9977 para la clase malignant. En LAB02, sobre 48.842 registros de Adult, el baseline marca 0,7607 de exactitud con recall 0,0000 para la clase `>50K` y el SVM llega a **0,8588 de exactitud, 0,7928 de F1 macro, 0,6146 de recall y 0,8840 de ROC-AUC** para `>50K`.

Lectura crítica. El contraste entre ambos resultados es la lección principal. En LAB01 el desempeño muy alto es coherente con un benchmark didáctico y bien estructurado; en LAB02 el mismo tipo de modelo deja fuera a **901 de 2.338 personas** que superan el umbral de ingreso. La causa no está en el algoritmo: `capital_gain` es cero en el 91,74 % de las filas y solo el 21,3 % de los casos `>50K` lo tienen positivo, de modo que la variable que más distingue los ingresos altos falta en cuatro de cada cinco casos positivos. A eso se suman 52 filas duplicadas, un censo de 1994–1996 sin contexto temporal y una población que no cubre a menores ni a personas sin ingresos declarados. Los 20 errores revisados, con semilla fija, **corrigen** una lectura anterior: de los 12 falsos negativos de la muestra, 6 tienen estudios secundarios (`HS-grad`) y 3 `Some-college`; solo 3 tienen estudios superiores (`Bachelors`) y 11 de 12 tienen `capital_gain` = 0 (el único con ganancia de capital, 3.103 USD, es un caso `HS-grad`). El desglose, calculado desde los datos, está en `reports/dataset_svm_errors_profile.csv`.

Decisión. Ambos pipelines se entregan como líneas base auditables, no como herramientas de decisión sobre personas. El siguiente experimento es medir el desempeño por grupo sin usar los atributos sensibles excluidos (`race`, `sex`, `native_country`), contrastar con un modelo capaz de representar la dispersión de `capital_gain` y repetir el análisis sobre una cohorte más reciente.

Estado pendiente: la aprobación del docente sobre el dataset del LAB02 sigue sin recibirse. El manual de la Unidad 01 prohíbe continuar con el entrenamiento final sin ella; el entrenamiento se ejecutó con la aprobación pendiente y así queda registrado en `reports/dataset_svm_metrics.json` (`aprobacion_docente: pendiente`). Los resultados de LAB02 corresponden a un censo de 1994-1996 de la población activa estadounidense: no son extrapolables y no autorizan decisiones sobre personas.

5. Referencias

Becker, B. y Kohavi, R. (1996). *Adult* (Census Income). UCI Machine Learning Repository. DOI 10.24432/C5XW20. Licencia CC BY 4.0.

Moro, S., Rita, P. y Cortez, P. (2014). A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*. DOI 10.1016/j.dss.2014.03.001.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825-2830.

Harper, E. W. y Konstan, J. A. (2012). *The Elements of Statistical Learning* (2.ª ed.). Springer. DOI 10.1007/978-0-387-84858-7.