# Ejercicio 01 · Dataset público y SVM reproducible

INF-8239 Ciencia de Datos II (UASD) · Unidad 01 · Integración de LAB01 y LAB02

| | |
|---|---|
| **Estudiante** | Edwing Perez · matrícula: PENDIENTE |
| **Profesor** | Edwin Ramón José Nolasco |
| **Repositorio** | https://github.com/edvvdev/unidad01-01 |
| **Fecha de ejecución** | 2026-11-02 |

## 1. Identificación del dataset (LAB02)

**Adult (Census Income)** · UCI Machine Learning Repository · licencia **CC BY 4.0** · URL `https://archive.ics.uci.edu/static/public/2/adult.zip` · ficha `https://archive.ics.uci.edu/dataset/2/adult`.
48,842 filas x 15 columnas; partición estratificada 80/20 con semilla 42 (39,073 entrenamiento / 9,769 prueba). Target **income** (<=50K / >50K, 23,93 % positivos). SHA-256 de los bytes descargados: `7537312dd56c2b98035880805ce99e68183a30ee468aa5329d6df0fbb3cc21bb`.
Variables usadas: age, workclass, education, education_num, marital_status, occupation, relationship, capital_gain, capital_loss, hours_per_week. Columnas excluidas por motivo semántico y de equidad: fnlwgt, race, sex, native_country. El candidato alterno evaluado fue *Bank Marketing* (UCI, CC BY 4.0), que exige excluir *duration* por fuga de información. La ficha comparativa completa está en `docs/ficha_dataset.md`.
**LAB01** usa el dataset de diagnóstico de mama de Wisconsin incluido en scikit-learn (569 muestras, 30 variables, 2 clases).

## 2. Tabla principal de resultados

| Laboratorio | Modelo | Accuracy | F1 macro | Recall |
|---|---|---|---|---|
| LAB01 · Wisconsin | DummyClassifier (baseline) | 0.6316 | 0.3871 | 0.0000 |
| LAB01 · Wisconsin | SVC rbf, C=10 gamma=0.01 | 0.9825 | 0.9812 | 0.9762 |
| LAB02 · Adult | DummyClassifier (mismo preprocesamiento) | 0.7607 | 0.4320 | 0.0000 |
| LAB02 · Adult | SVC rbf con pipeline, C=10 gamma=0.1 | 0.8588 | 0.7928 | 0.6146 |

Recall de la clase costosa: en LAB01 la clase maligno (0 = maligno); en LAB02 la clase **>50K**. F1 macro de validación: 0,9739 (LAB01, 5 folds) y 0,7759 (LAB02, submuestra estratificada del 25 %; el mejor modelo se reajustó sobre las 39.073 filas de entrenamiento). LAB02 deja fuera 901 de 2,338 casos que superan el umbral de ingreso.

## 3. Figuras

Figura 1. LAB01 · matriz de confusión del SVM sobre el conjunto de prueba.

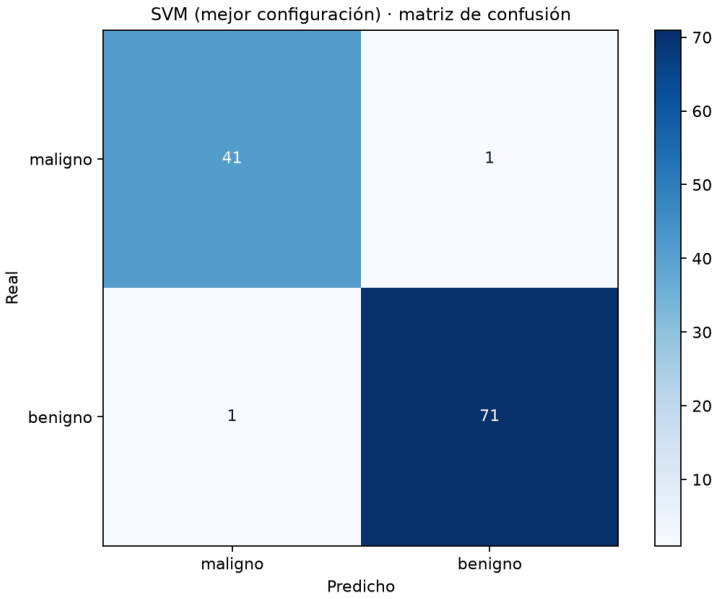
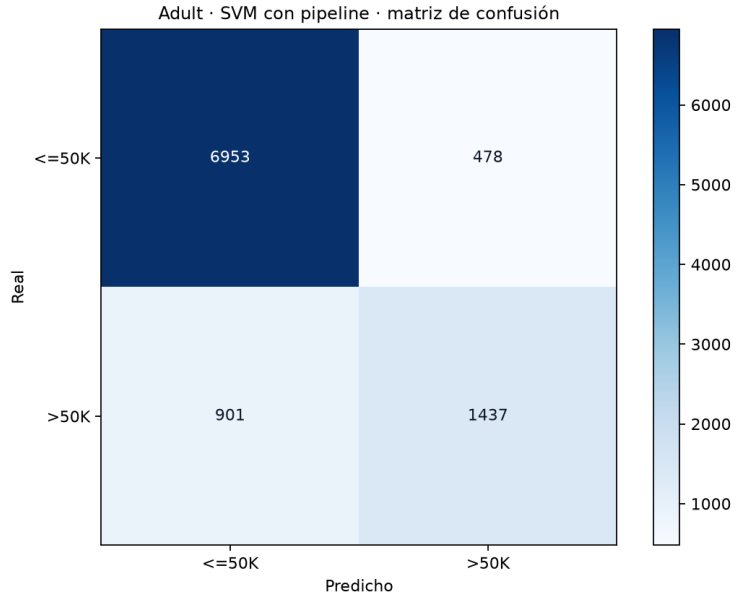



Figura 2. LAB02 · matriz de confusión del SVM con pipeline sobre el conjunto de prueba.



## 4. Conclusión

**Qué se construyó.** Dos experimentos reproducibles con el mismo esqueleto de proyecto: un pipeline de SVM con estandarización dentro del `Pipeline` sobre el dataset de diagnóstico de mama de Wisconsin (LAB01), y un pipeline completo con `ColumnTransformer` (imputación + escala para variables numéricas, imputación + codificación one-hot para categóricas) sobre el dataset público **Adult (Census Income)** de UCI (LAB02), elegido tras comparar dos candidatos verificados y documentado en `docs/ficha_dataset.md`.

**Resultados.** En LAB01 el baseline `DummyClassifier` alcanza 0,6316 de exactitud y 0,3871 de F1 macro (recall 0 para la clase maligno, porque predice siempre la mayoritaria) y el SVM con `C=10, gamma=0.01` llega a **0,9825 de exactitud y 0,9812 de F1 macro** en la prueba, con un único falso negativo sobre 42 casos malignos (recall 0,9762). En LAB02, sobre 48.842 registros de Adult, el baseline marca 0,7607 de exactitud con recall 0,0000 para la clase `>50K` y el SVM llega a **0,8588 de exactitud, 0,7928 de F1 macro y 0,6146 de recall** para `>50K`.

**Lectura crítica.** El contraste entre ambos resultados es la lección principal. En LAB01 el desempeño muy alto es coherente con un benchmark didáctico y bien estructurado; en LAB02 el mismo tipo de modelo deja fuera a **901 de 2.338 personas** que superan el umbral de ingreso. La causa no está en el algoritmo: `capital_gain` es cero en el 91,74 % de las filas y solo el 21,3 % de los casos `>50K` lo tienen positivo, de modo que la variable que más distingue los ingresos altos falta en cuatro de cada cinco casos positivos. A eso se suman 52 filas duplicadas, un censo de 1994–1996 sin contexto temporal y una población que no cubre a menores ni a personas sin ingresos declarados. Los 20 errores revisados, con semilla fija, confirman el patrón: los falsos negativos son personas con estudios superiores y `capital_gain` = 0 cuyo perfil no aparece en los ejemplos positivos.

**Decisión.** Ambos pipelines se entregan como líneas base auditables, no como herramientas de decisión sobre personas. El siguiente experimento es medir el desempeño por grupo sin usar los atributos sensibles excluidos (`race`, `sex`, `native_country`), contrastar con un modelo capaz de representar la dispersión de `capital_gain` y repetir el análisis sobre una cohorte más reciente.

**Estado pendiente:** la aprobación del docente sobre el dataset del LAB02 sigue sin recibirse. El manual de la Unidad 01 prohíbe continuar con el entrenamiento final sin ella; el entrenamiento se ejecutó con la aprobación pendiente y así queda registrado en `reports/dataset_svm_metrics.json` (`aprobacion_docente: pendiente`). Los resultados de LAB02 corresponden a un censo de 1994-1996 de la población activa estadounidense: no son extrapolables y no autorizan decisiones sobre personas.